

Fine-Tuning Chatbot Models Using Direct Preference Optimization (DPO)

1. Introduction

Trong bối cảnh phát triển các hệ thống hội thoại thông minh, việc điều chỉnh mô hình ngôn ngữ để phản hồi phù hợp với sở thích người dùng đang ngày càng trở nên quan trọng. Báo cáo này trình bày quy trình huấn luyện một mô hình chatbot sử dụng **phương pháp Direct Preference Optimization (DPO)** – một hướng tiếp cận mới nhằm tối ưu hóa phản hồi dựa trên các cặp phản hồi “được chọn” và “bị loại”. Không giống như các phương pháp như PPO hay SFT, DPO học trực tiếp từ lựa chọn ưu tiên mà không cần đánh giá phần thưởng (reward modeling).

2. Implementation Process

2.1. Dataset

Dữ liệu sử dụng là tập hợp các cặp:

- **Prompt:** câu hỏi đầu vào.
- **Chosen:** phản hồi được ưa thích.
- **Rejected:** phản hồi kém chất lượng hoặc không phù hợp.

Dữ liệu này đã được tokenize và lưu dưới định dạng JSON (`tokenized_dpo.json`), sẵn sàng để huấn luyện với `DPOTrainer`.

2.2. Mô hình và kỹ thuật

- **Base model:** `EleutherAI/pythia-70m`
- **Ref model:** cùng một bản gốc (không cập nhật tham số)
- **Thư viện sử dụng:** `transformers`, `trl`, `peft`
- **Chiến lược huấn luyện:** Direct Preference Optimization
- **Hyperparameters:**
 - `per_device_train_batch_size=8,`

- `per_device_eval_batch_size=8,`
- `num_train_epochs=1,`
- `logging_steps=50,`
- `eval_strategy='steps',`
- `learning_rate = 1e-5`
- `eval_steps=100,`
- `save_strategy="no",`
- `report_to="none",`
- `beta=0.3,`
- `max_prompt_length=256,`
- `max_length=200,`
- `padding_value=tokenizer.pad_token_id,`
-

2.3. Training Pipeline

Mô hình được huấn luyện bằng `DPOTrainer`, trong đó:

- **model**: là mô hình `pythia-70m` đã áp dụng LoRA.
- **ref_model**: là bản freeze của mô hình gốc (không học).
- **beta** điều khiển mức độ phân biệt giữa phản hồi chosen và rejected.
- Loss được tính dựa trên logit của chosen vs rejected, không yêu cầu normalize hay reward như PPO.

3. Challenges and Solutions

Vấn đề	Giải pháp đã triển khai
<code>DPOTrainer</code> không nhận đối số <code>beta</code>	Kiểm tra lại version <code>trl</code> , dùng đúng cấu trúc <code>DPOConfig</code> mới nhất
Thiếu <code>train_output</code> sau <code>.train()</code>	Gán <code>train_output = trainer.train()</code> để lấy kết quả rõ ràng
Thiếu tài nguyên GPU	Sử dụng <code>LoRA</code>
Dữ liệu JSON bị lỗi định dạng	Viết script kiểm tra và chuẩn hóa lại tất cả cặp prompt-response

4. Results and Observations

Chỉ số	Kết quả
Train Loss giảm	Từ ~1.9 xuống còn ~0.35
Tốc độ huấn luyện	~4s/step trên Kaggle T4
Sự ưu tiên phản hồi chosen	Tăng đáng kể

Ví dụ cụ thể:

- **Prompt:** “What is the capital of Spain?”
 - **Rejected:** “Spain is a country in Europe.”
 - **Chosen:** “The capital of Spain is Madrid.”
 - → Sau khi huấn luyện, mô hình bắt đầu sinh phản hồi chính xác như “Madrid is the capital of Spain.”

5. Conclusion

Việc sử dụng **DPO** giúp tinh chỉnh mô hình ngôn ngữ một cách hiệu quả theo sở thích người dùng, **không cần reward modeling hoặc supervised fine-tuning (SFT)**. Với mô hình nhỏ như **pythia-70m**, kết hợp LoRA, ta vẫn đạt được kết quả đáng kể với chi phí tài nguyên thấp. Phương pháp DPO phù hợp cho các hệ thống hội thoại cần ưu tiên chất lượng phản hồi hơn là độ chính xác tuyệt đối.